DATASCAPE 2026 — Write-Up

Klasifikasi Kondisi Paket E-Commerce (Aman / Rusak / Lainnya)

Kompetisi: DATASCAPE 2026 — Data Mining Competition, HIMA DS Telkom University
Metrik: Macro-Averaged F1-Score (rata-rata F1 per kelas, tidak berbobot)
Hasil terbaik (public LB): 0.79539
Cross-validation terbaik (OOF): 0.8666 ± 0.0117 (5-fold, convnext_base)

1. Ringkasan Eksekutif

Kami membangun klasifikasi kondisi paket tiga kelas berbasis CNN (ConvNeXt) dengan fokus pada tiga hal: (1) validasi yang jujur terhadap duplikat gambar, (2) augmentasi yang menyerang distribution shift train→test, dan (3) keputusan berbasis cross-validation (bukan public leaderboard). Temuan utama kami: bottleneck performa bukan kapasitas model, melainkan label noise pada data test — banyak gambar berlabel "Rusak" yang secara visual utuh.

2. Dataset & Audit

- Train: 12.224 gambar (Aman 8.800 / Rusak 3.001 / Lainnya 423 → rasio 21 : 7 : 1).
- Test: 3.057 gambar.
- Integritas: 0 file corrupt dari 15.281 gambar (diverifikasi PIL.Image.verify() + decode penuh). Mode warna heterogen (RGB/RGBA/P) → dinormalisasi ke RGB saat load.
- Resolusi: sangat heterogen (37–8000 px, aspect ratio 0.3–4.3). 22,2% gambar train di luar aspect 0.75–1.33 → diputuskan PAD ke persegi (bukan squash) agar geometri paket tidak terdistorsi.

2.1 Near-duplicate & leakage (temuan kunci)

Dataset ini hasil *web-scrape* dan mengandung banyak duplikat:
- 36,6% gambar test (1.119/3.057) punya near-duplicate di train (623 grup lintas-split, 886 pasangan exact/pixel-identical), dideteksi dengan perceptual hash (pHash, Hamming ≤ 6).
- Label noise: 122 pasangan gambar train yang identik-piksel tetapi berlabel berbeda (dominan Aman↔Rusak). Ini berarti sebagian label memang ambigu/salah.
- Implikasi: split acak biasa akan membocorkan duplikat ke validasi → CV terlihat lebih tinggi dari kenyataan. Karena itu kami memakai validasi *group-aware* (lihat §3).

3. Strategi Validasi (inti reproduksibilitas)

- Skema: StratifiedGroupKFold(n_splits=5, shuffle, seed=42), dikelompokkan per group_id pHash. Satu grup duplikat tidak pernah terpecah ke train dan validasi sekaligus.
- Fold dibekukan (folds.csv, 9.906 grup; 91 grup campur-label dibiarkan utuh dalam satu fold). Semua eksperimen memakai assignment fold yang sama → perbandingan antar-model sah.
- Baseline titik nol: majority class (selalu "Aman") macro-F1 = 0.2790. Semua model kami jauh di atas ini.
- Aturan eksperimen: selisih skor di bawah standar-deviasi antar-fold dianggap seri (bukan kemenangan), sehingga kami tidak mengejar noise.

4. Distribution Shift & Augmentasi

Adversarial validation (model membedakan train vs test) menghasilkan AUC 0.866 = drift kuat. Pembeda utamanya bukan konten, melainkan artefak teknis: kompresi (bits-per-pixel), ukuran file, dan resolusi. Artinya model bisa "curang" dengan menempel pada artefak kompresi alih-alih kondisi paket.

Mitigasi — augmentasi yang menyerang drift tersebut (hanya di train):
- JPEG compression acak (quality 20–90) dan random downscale (0.4–0.9) → memaksa model robust terhadap variasi kompresi/resolusi.
- RandomResizedCrop, horizontal flip, affine ringan, ColorJitter, RandomErasing.
- Validasi & test memakai transform deterministik yang identik (test-time parity).

5. Model & Training

- Backbone utama: convnext_base.fb_in22k_ft_in1k_384 (ConvNeXt-Base, pretrain ImageNet-22k → 1k, input 384px) via timm. Pemilihan berbasis evidence: ConvNeXt konsisten kuat di data kecil; pretrain IN-22k (14M gambar) lebih kaya dari IN-1k.
- Recipe: AdamW (LR backbone 1e-4, head 1e-3), weight decay 1e-2, cosine schedule + warmup, AMP fp16, batch 16, 20 epoch, checkpoint terbaik per-fold.
- Class imbalance: class-weighted CrossEntropy + label smoothing 0.1. Formula default N/(3·count) memberi kelas "Lainnya" bobot 9,63× dan membuat model *over-predict* kelas langka → kami cap bobot di 3,0, yang mengembalikan kalibrasi (distribusi prediksi OOF kembali ≈ distribusi train) tanpa patch saat inference.
- Final prediction: fold-mean — rata-rata probabilitas dari 5 model fold. Dipilih dibanding refit-full karena data kecil + CV high-variance (tidak ada val set untuk refit).

Hasil per model (OOF macro-F1 di fold beku)

Model	OOF macro-F1	fold std
majority (titik nol)	0.2790	0.000
LogReg (mean-pixel)	0.2983	—
resnet18 @384	0.6634	0.0180
convnext_tiny @512	0.8464	0.0110
convnext_base @384 (IN-22k)	0.8666	0.0117
DINOv2 frozen + linear probe	0.7599	0.0146
DINOv2 frozen + kNN	0.7656	0.0104

6. Ensembling — apa yang berhasil dan apa yang tidak

Kami menguji semua kombinasi blend (equal-mean dan optimasi simplex di OOF):
- convnext_base + convnext_tiny + dinov2_knn = 0.8737 OOF (terbaik di OOF).
- Namun saat disubmit, blend ini justru lebih rendah dari convnext_base solo di LB (0.77027 vs 0.79539).

Analisis kegagalan blend: blend membalik 128 label test vs base-solo, 96 netto Rusak→Aman, terkonsentrasi pada kasus yang memang sudah tidak yakin (confidence rendah) — tepat di boundary Aman↔Rusak yang paling noisy. Di OOF pembalikan ini netto-benar; di test nyata netto-salah. Ini bukti overfit ke OOF pada boundary yang noisy dan *distribution gap* OOF↔LB.

Pelajaran yang kami dokumentasikan: model yang menang di OOF belum tentu menang di test ketika test mengandung label noise. Kami memilih model terkuat tunggal sebagai dasar submission final, bukan blend paling kompleks.

7. Near-Duplicate Calibration

Karena 36,6% test adalah salinan train, kami menerapkan kalibrasi deterministik:
- Hanya untuk gambar test yang masuk grup pHash yang 100% satu label di train (unanimous, tanpa ambiguitas), labelnya dipakai.
- Ini adalah lookup struktur data yang deterministik, bukan inference model — dan hanya diterapkan pada 958 gambar (58 di antaranya mengubah prediksi model).
- Grup yang labelnya campur (161 gambar) tidak disentuh (diserahkan ke model).
- Efek terukur: +0.0078 pada model sebelumnya; konsisten memperbaiki error nyata (spot-check visual menunjukkan label "Rusak" yang dioverride memang paket utuh).

8. Error Analysis & Diagnosis Ceiling

Confusion matrix OOF (convnext_base):
- Rusak→Aman: 850 kasus (28% dari kelas Rusak) — pasangan paling sulit.
- Aman→Rusak: 480; Lainnya→Aman: 61.
- Per-class F1: Aman 0.92, Rusak 0.76, Lainnya 0.86.

Inspeksi gambar worst-error (dibaca manual) menemukan banyak gambar berlabel "Rusak" yang sebenarnya paket utuh secara visual, serta keberadaan watermark iStock / thumbnail YouTube.
Verdict: bottleneck = label noise pada data (termasuk test), bukan kapasitas model.
Konsekuensinya: menaikkan ukuran backbone lebih jauh tidak akan banyak membantu; perbaikan terbesar justru dari pembersihan label (di luar kendali peserta) dan kalibrasi.

8.1 Interpretabilitas (Grad-CAM)

Kami membangkitkan Grad-CAM (heatmap di atas blok konvolusi terakhir) pada contoh worst-error dan contoh yang benar di ketiga kelas — lihat artifacts/gradcam_grid.jpg (kiri = gambar asli, kanan = overlay heatmap; merah = region paling berpengaruh).
- Pada kasus benar, heatmap terfokus pada area paket/label → model melihat objek yang benar.
- Pada kasus salah (terutama Aman→Lainnya), heatmap tidak tertipu watermark — tetap di paket, tetapi menyebar ke tepi/logo samping atau (pada satu kasus dua dus bertumpuk) tertarik ke celah bayangan antar-dus/latar. Artinya kesalahan bukan karena model melihat artefak, melainkan karena region bukti yang lemah/tidak fokus pada objek yang memang ambigu.
- Ini memperkuat diagnosis ceiling: ketika objek sudah benar tetapi label tetap salah (atau bukti visualnya lemah), sumber error adalah ambiguitas/noise data, bukan shortcut artefak.

9. Hasil & Posisi

Submission	Model	OOF/CV	Public LB
baseline	LogReg mean-pixel	0.2983	0.29522
#2	resnet18 + TTA + class-scale	0.7847	0.74324
#3	convnext_tiny	0.8464	0.77186
#4	convnext_tiny + near-dup	0.8464	0.77968
#5	blend3 (base+tiny+dinov2_knn) + near-d	0.8771	0.77027

#6 (final)	convnext_base + near-dup	0.8666	0.79539

Public LB terbaik kami 0.79539 (peringkat ~42 dari 47 tim pada saat penulisan).
Gap OOF→LB sekitar -0,07 konsisten dengan adanya label noise di test (model dinilai terhadap label yang sebagian salah).

10. Limitasi & Arah Perbaikan

1. Label noise adalah ceiling utama — akurasi maksimum dibatasi kualitas anotasi, bukan model.
2. Distribution shift (kompresi/resolusi) belum sepenuhnya tertutup oleh augmentasi.
3. Public LB hanya 30% test — skor akhir ditentukan 70% private; kami memilih kandidat final berdasarkan CV (lebih stabil) daripada mengejar public LB.
4. Perbaikan selanjutnya: pembersihan label, confident learning untuk menyaring anotasi salah, dan TTA multi-scale (TTA hflip kami uji hanya memberi +0.00002 sehingga tidak dipakai).

11. Reproducibility & AI Declaration

- Seed 42 global; fold dibekukan; semua eksperimen pada fold yang sama; script pipeline tunggal kaggle_all_in_one.py (mode --stage {audit,phash,folds,train,ensemble,submit}).
- External data: tidak ada. Hanya data resmi kompetisi. Pretrained weights (ImageNet / IN-22k, kategori library/model yang diizinkan) dipakai dan dideklarasikan: convnext_tiny, convnext_base.fb_in22k_ft_in1k_384, DINOv2 (hanya untuk probe/eksperimen, tidak dipakai pada submission final).
- AI Declaration: pengembangan dibantu asisten AI (Hermes Agent / LLM via CommandCode) sebagai alat *pair-programming*, debugging, dan penyusunan dokumentasi. Tidak ada AI/VLM/LLM yang dipakai untuk inference atau menghasilkan prediksi test — seluruh prediksi berasal dari CNN yang dilatih (fold-mean 5 fold) ditambah kalibrasi near-duplicate yang deterministik.
- Semua keputusan teknis tercatat di decision_log.md (D0–D23) dan metrics_summary.csv.